Double Descent Phenomenon

Egy model kapacitásának növelése egy adott pontig csökkenti a teszt hibát, ezt követően a teszt hiba nő, majd az interpolációs küszöbön túl, a hiba ismét elkezd csökkenni.

Schaeffer, Rylan, et al. (2023)

Belkin, Mikhail, et al. (2019)

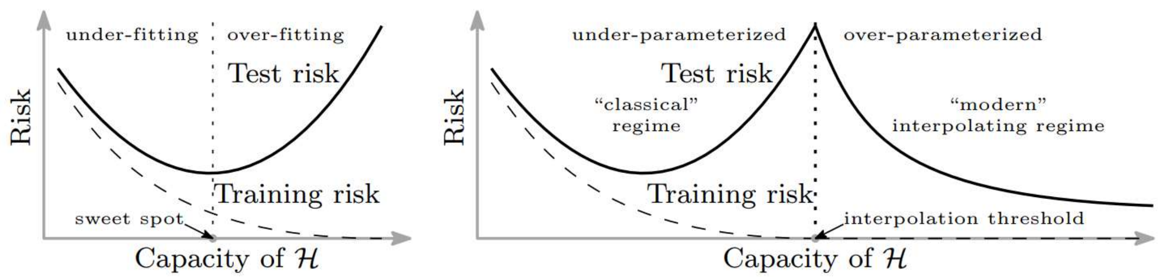

Jelölés

$\mathcal{D} = \{(x_1, y_1), \ldots, (x_n, y_n)\},\ |\mathcal{D}| = N$

$(x_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$

$f : \mathbb{R}^d \mapsto \mathbb{R}$

$f \in \mathcal{H}$ függvény család

Classical Bias-Variance trade-off

1. Ha $\mathcal{H}$ kapacitása kicsi (*high bias*), akkor minden $f \in \mathcal{H}$ nem illeszkedik megfelelő mértékben a tanulási adatokra (*under-fitting*), ezért új adatokra is rossz eredményeket fog adni.
2. Ha $\mathcal{H}$ kapacitása nagy (*high variance*), akkor léteznek $f \in \mathcal{H}$ amelyek tökéletesen illeszkednek a tanulási adatokra (*over-fitting*), viszont nem képesek általánosítani, ezért új adatokra rossz eredméyeket fognak adni.

Ezek alapján $\mathcal{H}$-t úgy kell kiválasztani, hogy a kapacitása a *sweet spot*-ban legyen

"Modern" Interpolating Regime

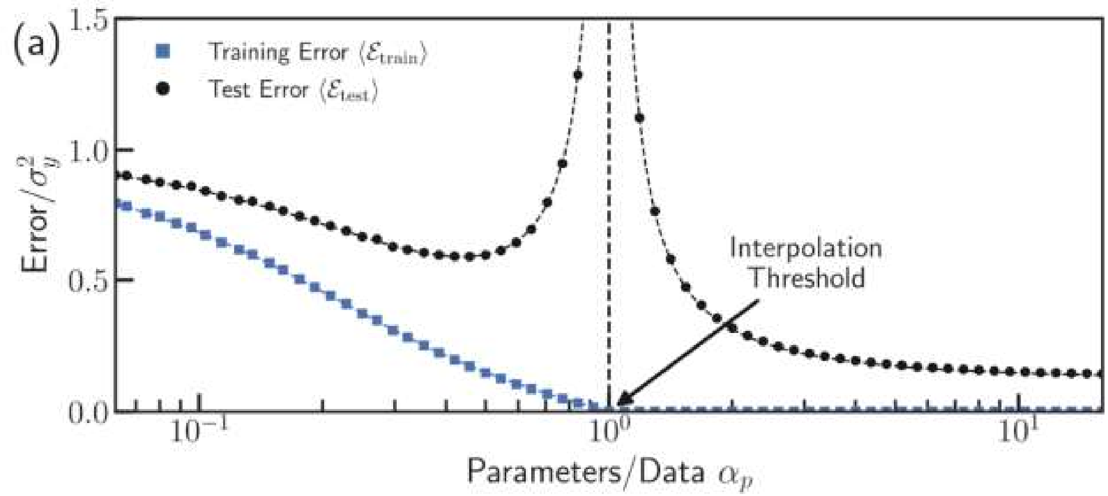

Ha $\mathcal{H}$ kapacitását növeljük, az interpolációs küszöbön túl , a tanulási hiba 0 marad, viszont a test hiba ismét elkezd csökkenni. Ez ellentmond a bias-variance trade-off elvnek.

Egyszeűsített intuitív magyarázat. Az interpolációs küszöbön 1 függvény létezik, ami képes tökéletesen illeszkedni a tanulási adatokra, annak a valószínűsége, hogy ez a függvény új adatokra is illeszkedni fog eléggé alacsony. Az interpolációs küszöbön túl, több függvény fog tökéletesen illeszkedni az adatokra, tehát annak a valószínűsége, hogy létezik ezek között legalább egy olyan amely új adatokra is megfelő predikciókat ad, nagyobb.

Vizuális Intuició Polinomiális Regresszióval

$y : \mathcal{R} \mapsto \mathcal{R}$

$y(x) = 2x + cos(25x)$

$\phi_P : \mathcal{R} \mapsto \mathcal{R}^P$

$$\phi_P(x) = \begin{bmatrix} \phi_1(x) \\ \phi_2(x) \\ \vdots \\ \phi_P(x) \end{bmatrix}$$

$y \approx \phi_P(x) \cdot \Theta_P$

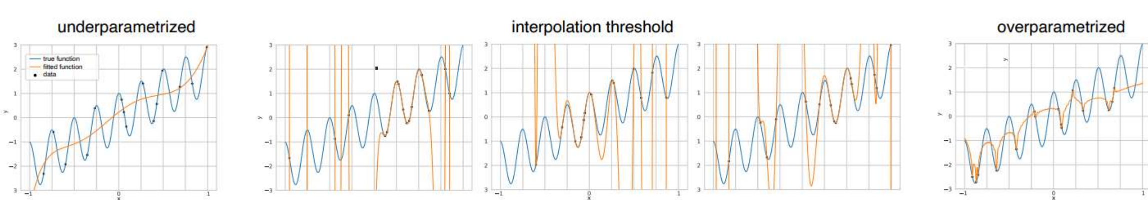


```
In [ ]: using Random, Statistics, Plots, LinearAlgebra, Polynomials
```

```julia
f(x) = 2 .* x .+ cos.(25 .* x)

# Sample Train Data
n_train = 5
x_train = sort(2π * rand(n_train))
y_train = f(x_train)

n_test = 60
x_test = sort(2π * rand(n_test))
y_test = f(x_test)

degrees = 0:10
test_errors = []
train_errors = []
polynomials = []

for d in degrees
    # Fit a Polynomial of degree d to the train data
    p = Polynomials.fit(x_train, y_train, d)
    push!(polynomials, p)
    y_pred = evalpoly.(x_test, p)
    y_train_pred = evalpoly.(x_train, p)
    push!(test_errors, mean((y_pred .- y_test).^2))
    push!(train_errors, mean((y_train_pred .- y_train).^2))
end

p = plot(degrees, test_errors, lw=2, xlabel="Polynomial degree (d)", ylabel="MSE", leg
plot!(degrees, train_errors, lw=2)
```

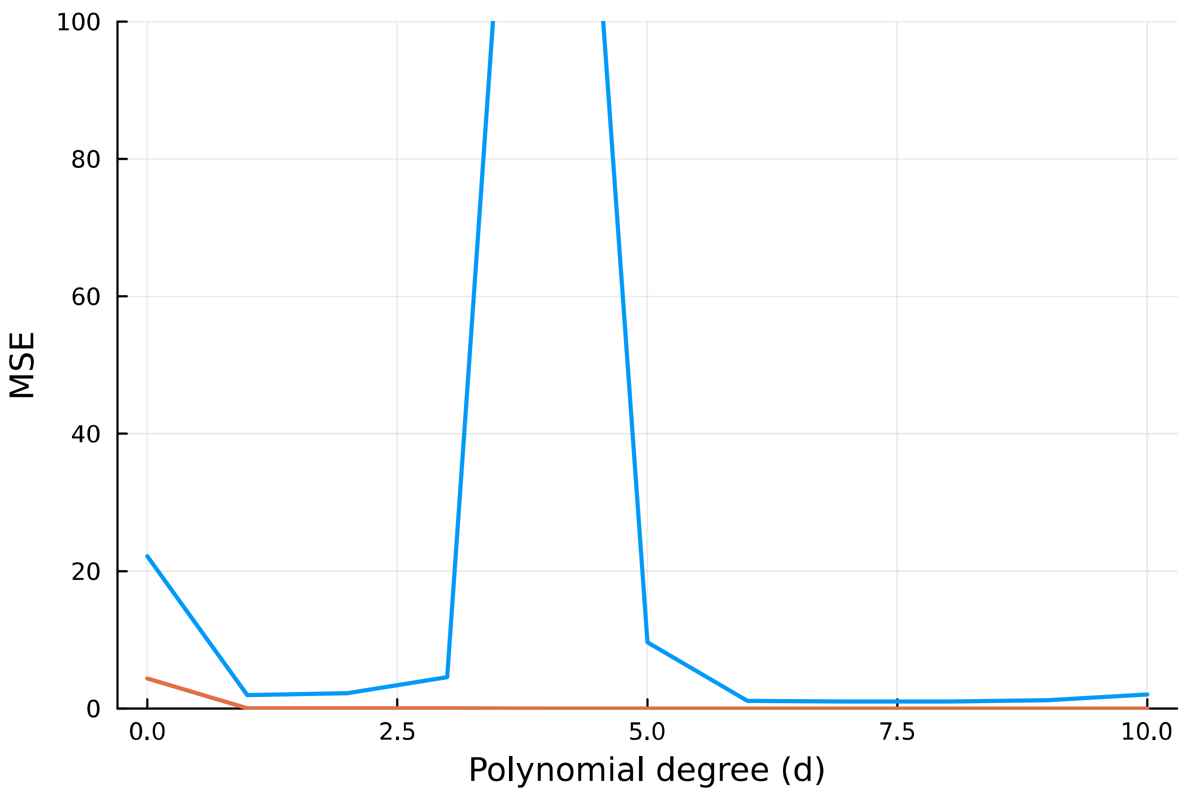

In [509…

```julia
p = scatter(x_train, y_train, layout=(1,3), legends=false, xlims=(0,6), ylims=(0,12),
scatter!(p[2], x_train, y_train, legends=false)
scatter!(p[3], x_train, y_train, legends=false)
scatter!(p[1], x_test, y_test)
scatter!(p[2], x_test, y_test)
```

```
scatter!(p[3], x_test, y_test)

plot!(p[1], polynomials[2], xlims=(0,6), ylims=(0,12))
plot!(p[2], polynomials[5], xlims=(0,6), ylims=(0,12))
plot!(p[3], polynomials[10], xlims=(0,6), ylims=(0,12))
```

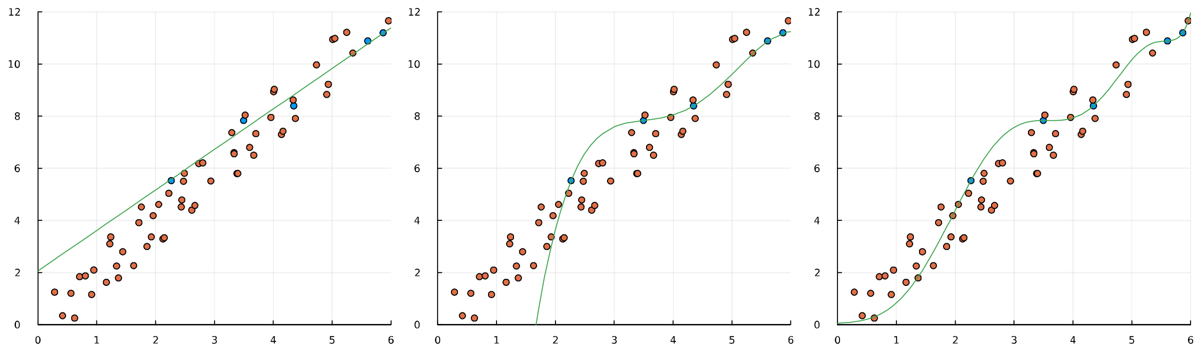

Matematikai Intuició Lineáris Regresszióval

$Y = X \cdot \Theta$

Lineáris regresszió esetében $P = D$. Mivel a paraméterek száma nem növelhető, az adatok számát fogjuk csökkenteni.

1. Ha $P < N$

   $\hat{\Theta}_{under} = \underset{\Theta}{argmin} ||X\Theta - Y||^2$

   Megoldás: $\hat{\Theta}_{under} = (X^T X)^{-1} X^T Y$

2. Ha $P > N$

   $\hat{\Theta}_{over} = \underset{\Theta}{argmin} ||\Theta||^2,\ \forall n \in \{1, \ldots, N\}\ x_n \cdot \Theta = y_n$

   Megoldás: $\hat{\Theta}_{over} = X^T (X X^T)^{-1} Y$

$\hat{y}_{test,under} = x_{test} \cdot \hat{\Theta}_{under} = x_{test} \cdot (X^T X)^{-1} X^T Y$

$\hat{y}_{test,over} = x_{test} \cdot \hat{\Theta}_{over} = x_{test} \cdot X^T (X X^T)^{-1} Y$

Jelöljuk Θ*-al az ismeretlen ideális paramétereket amikre minimális a teszt hiba

Tehát $Y = X\Theta^* + E$, ahol E az adat megtanulhatatlan része

Ezt használva írjuk át a predikciót a két esetben

1. P < N

   $\hat{y}_{test,under} = x_{test} \cdot (X^T X)^{-1} X^T Y$

   $= x_{test} \cdot (X^T X)^{-1} X^T (X\Theta^* + E)$

$$= x_{test} \cdot (X^T X)^{-1} X^T X \Theta^* + x_{test} \cdot (X^T X)^{-1} X^T E$$

$$= x_{test} \cdot \Theta^* + x_{test} \cdot (X^T X)^{-1} X^T E$$

$$x_{test} \cdot \Theta^* \stackrel{def}{=} y^*_{test}$$

$$\hat{y}_{test,under} - y^*_{test} = x_{test} \cdot (X^T X)^{-1} X^T E$$

$$(X^T X)^{-1} X^T = X^+ = V \Sigma^+ U^T$$

$$\hat{y}_{test,under} - y^*_{test} = x_{test} \cdot V \Sigma^+ U^T E = \sum_{r=1}^{R} \frac{1}{\sigma_r} (x_{test} \cdot v_r)(u_r \cdot E)$$

2. P > N, a számítás hasonló (exercise for the reader)

$$\hat{y}_{test,over} - y^*_{test} = \sum_{r=1}^{R} \frac{1}{\sigma_r} (x_{test} \cdot v_r)(u_r \cdot E) + x_{test} \cdot (X^T (X X^T)^{-1} X - I_d) \Theta^*$$

A két egyenlet arra mutat, hogy a teszt hibát 3 érték fog meghatározni:

1. Mennyire változnak a tanulási adatok minden irányban: $\frac{1}{\sigma_r}$
2. Mennyire és milyen irányokban változnak a teszt adatok relatív a tanulási adatokhoz képest: $x_{test} \cdot v_r$
3. Mennyire képes az ideális modell megtanulni a tanulási adatokat: $u_r \cdot E$

Miért a legnagyobb a hiba az interpolációs küszöbön?

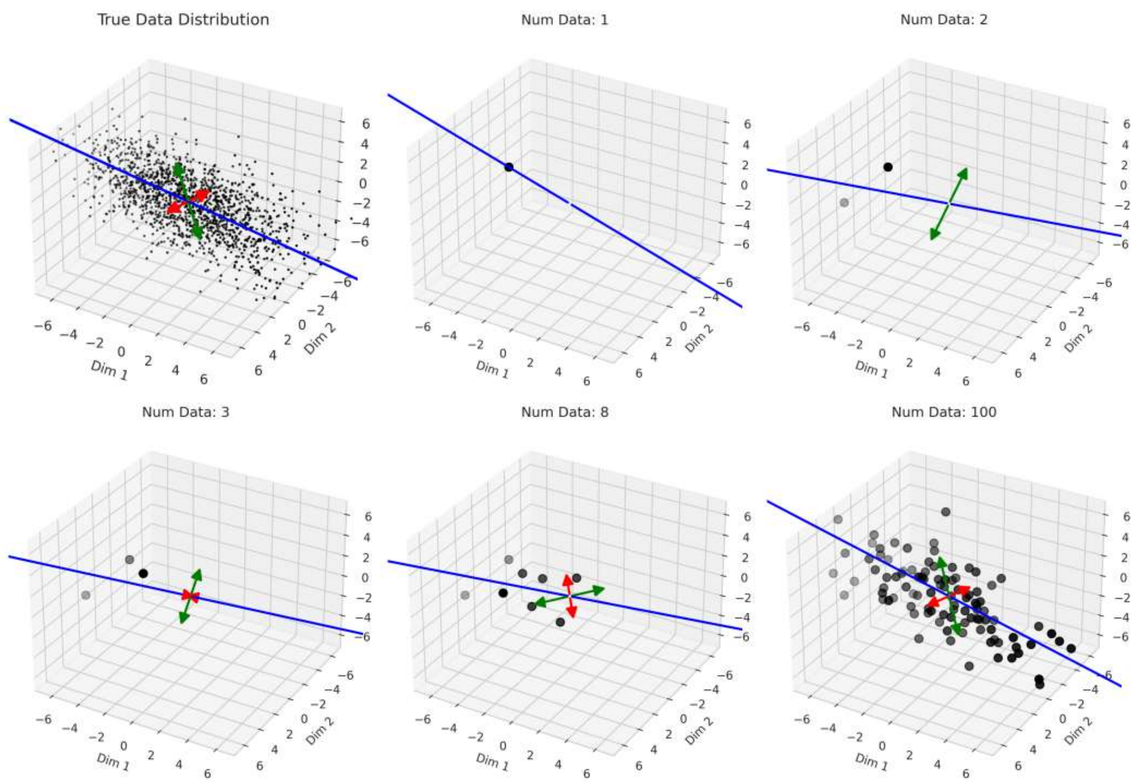

Mikor nem történik Double Descent?

- Nincsenek nullához közeli szinguláris értékek (σ_r)
- A teszt adatok nem változnak más irányokban mint a tanulási adatok
- Az ideális model tökéletes illeszkedik a tanulási adathalmazra (E=0)